MUSA 从入门到精通
实验讲解

讲解人 课程助教 肖同欢

国家高性能计算中心(合肥)、信息与计算机国家级实验教学示范中心

计算机科学与技术学院

2025年10月09日

内容

- 实验入口
- 提交内容
- 提交方式

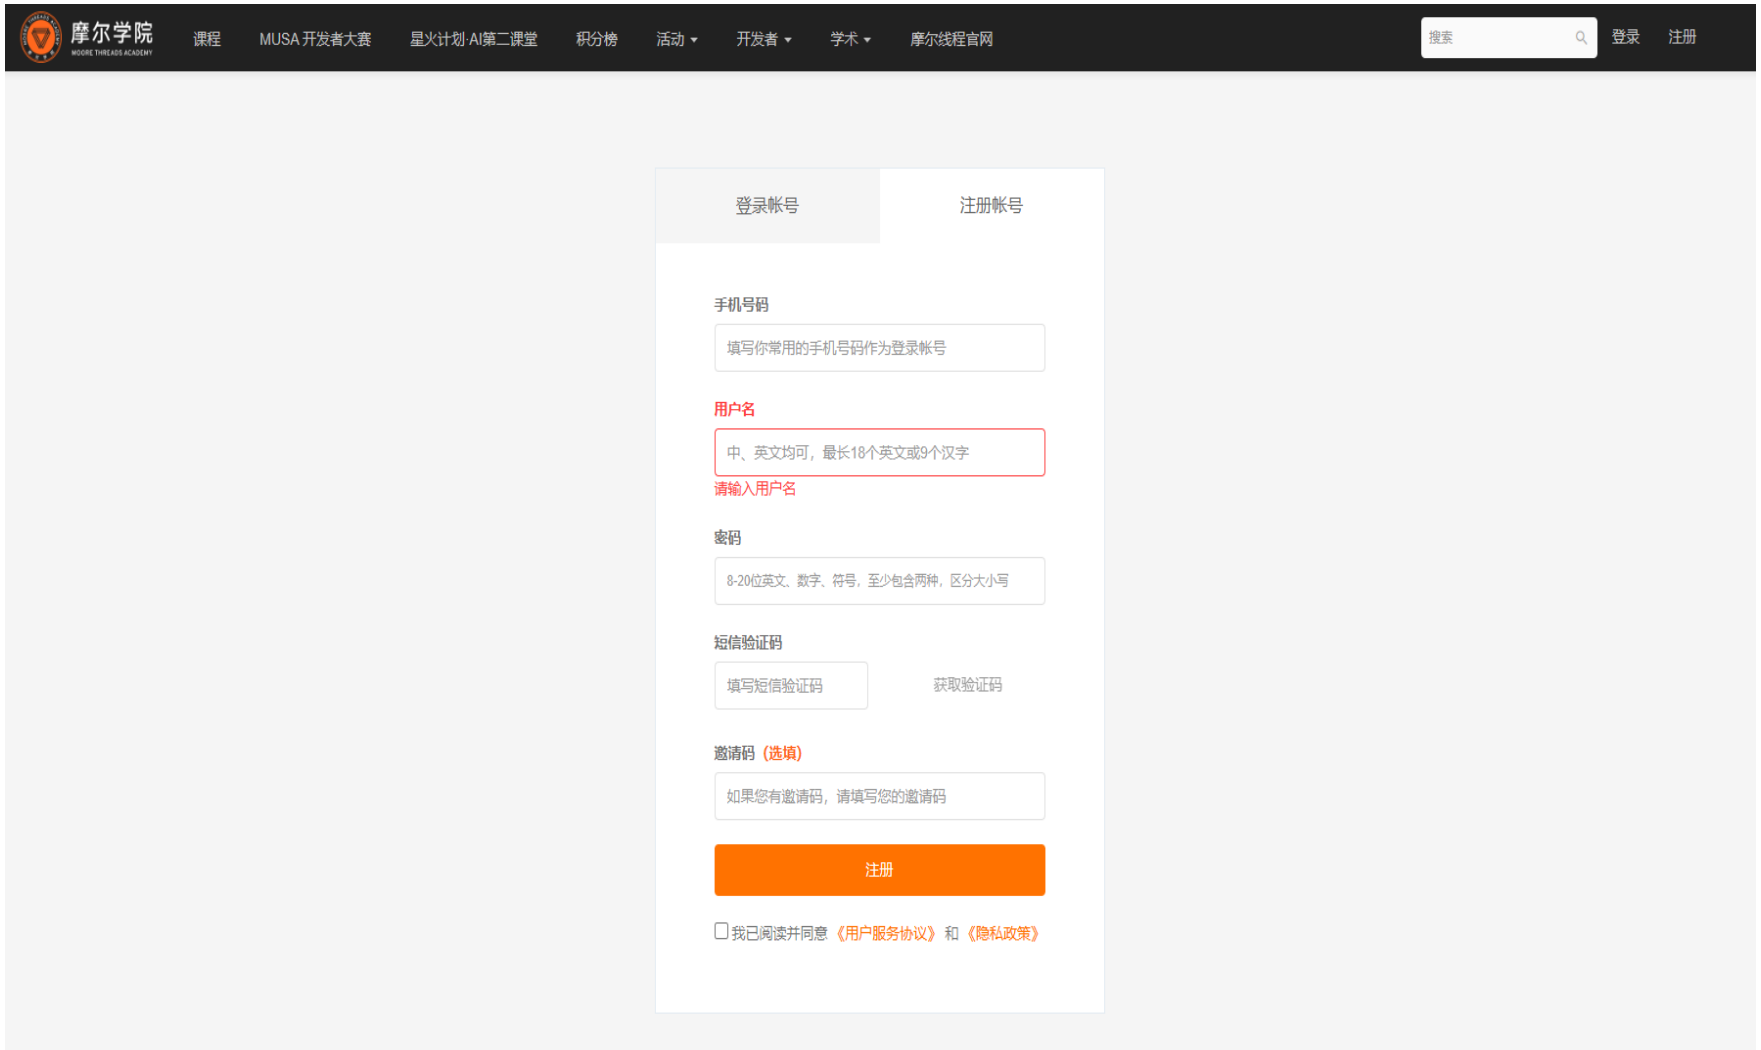
实验准备

- 打开摩尔线程官网（https://academy.mthreads.com/），注册账号



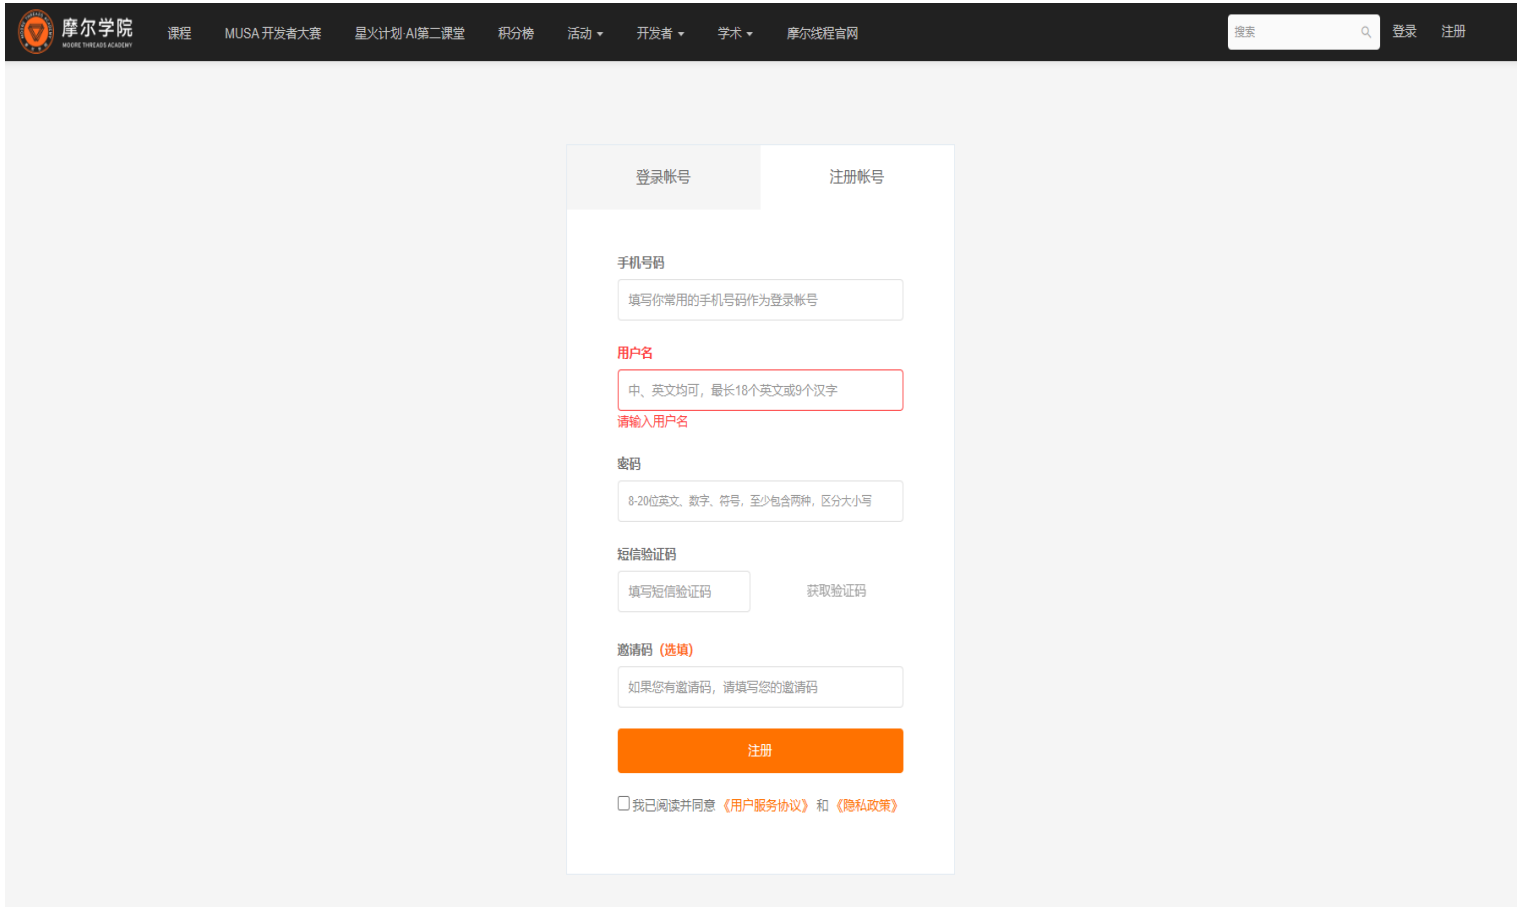
实验准备

- 打开摩尔线程官网（https://academy.mthreads.com/），注册账号



实验准备

- 账号注册完成之后填课程群腾讯文档，收集账号信息，助教会邀请大家加入课程



实验准备

- 进入中国科学技术大学《编译工程》课程



实验准备

- 进入中国科学技术大学《编译工程》课程



实验介绍

- 算子实验两部分，要求完成所有课程，掌握基本的算子编写技巧，完成端到端实战，并完成在希冀平台发布的算子题目，课程分为两部分
  - 第一部分 MUSA 编程，学习使用 MUSA 对 GPU 进行编程
  - 第二部分算子实战，介绍大模型中常见算子，并对 Triton，TileLang 进行介绍，最后介绍算子 integrate 进入大模型，进行端到端的测试

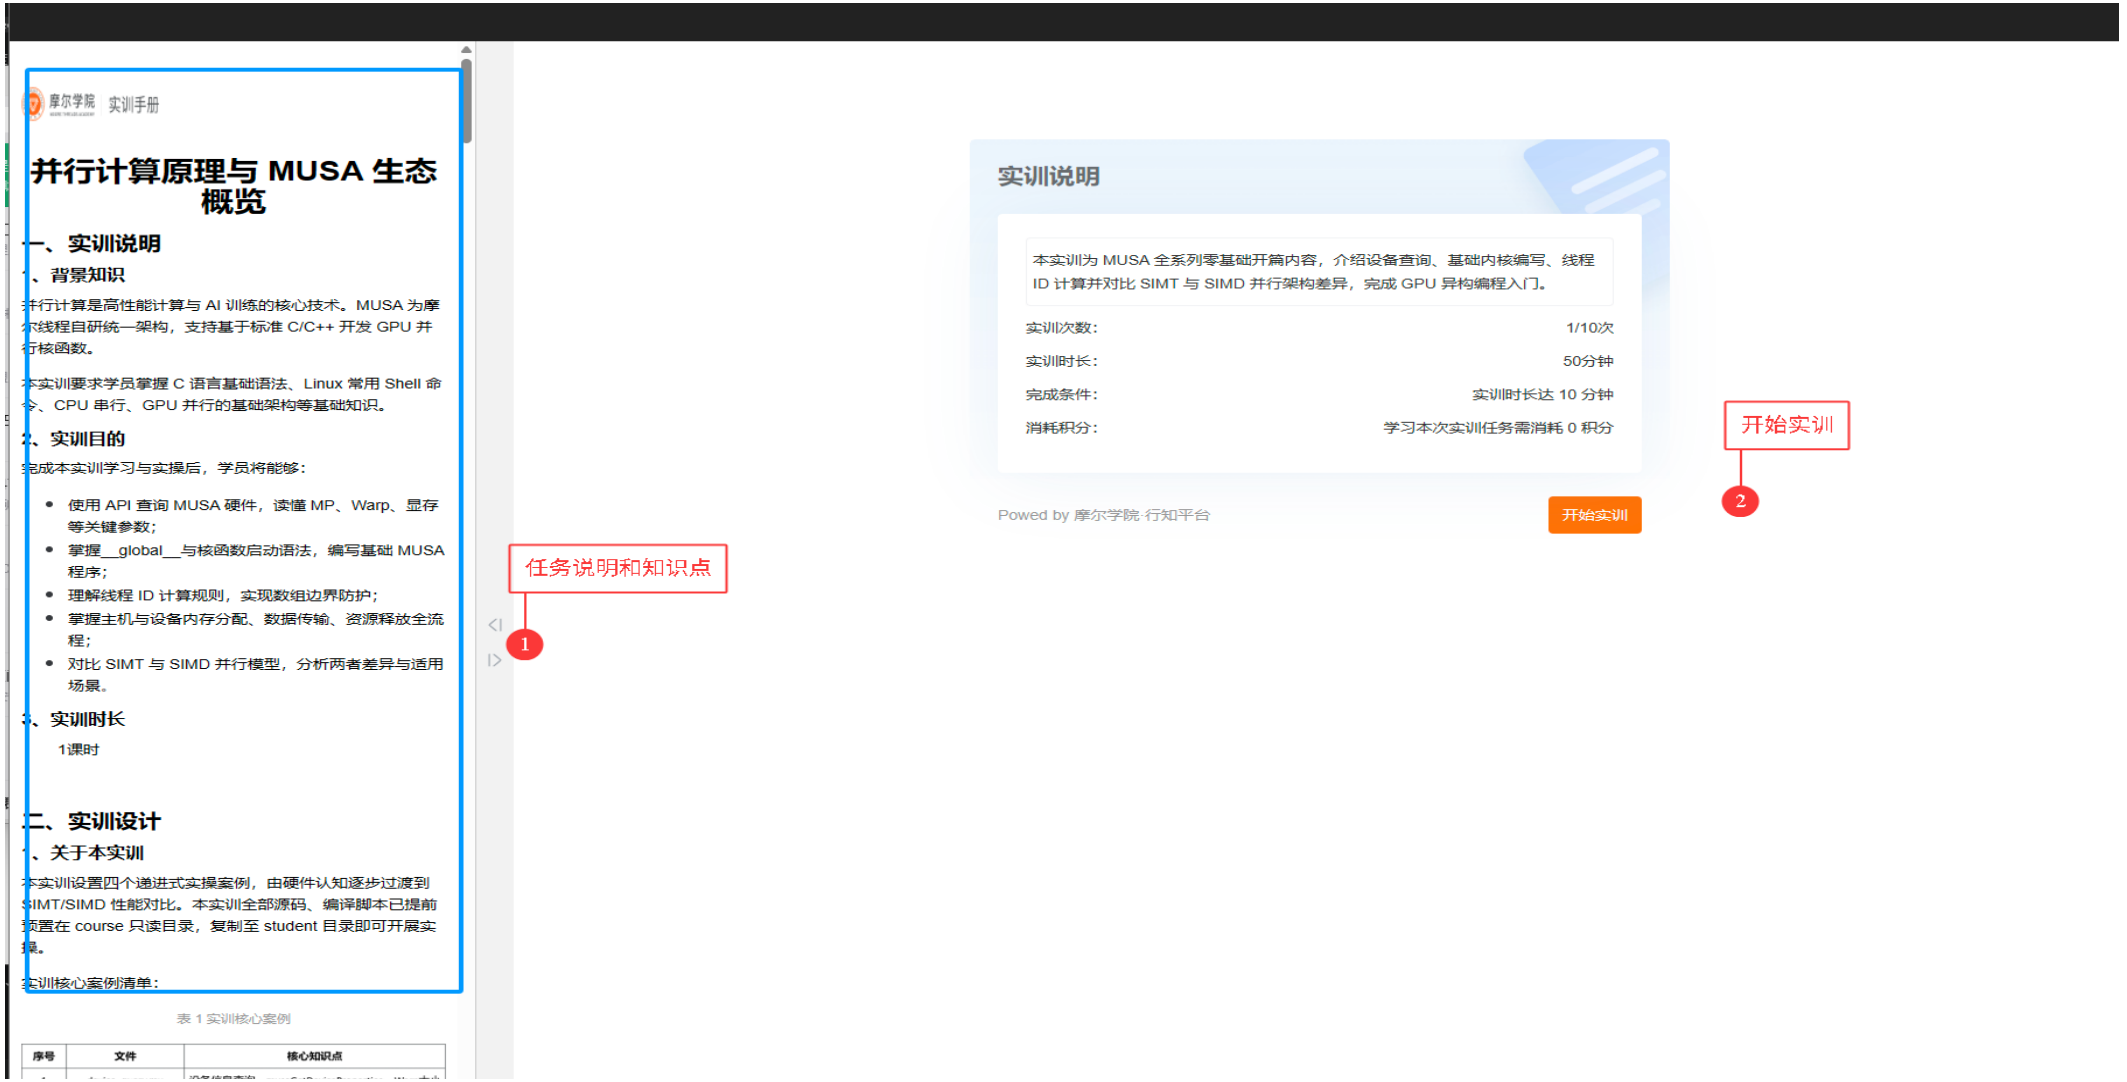
实验准备

- 进入中国科学技术大学《编译工程》课程，点击去学习



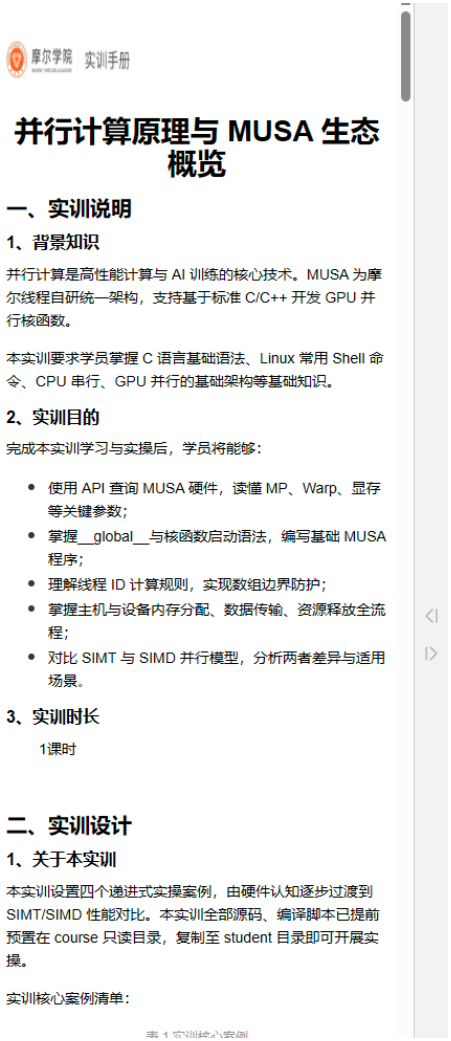
实验阶段：以课时1为例

- 第一个课MUSA生态学习，类似CUDA



实验阶段：以课时1为例

- 等待时间可能较长，请耐心



摩尔学院 实训手册

并行计算原理与 MUSA 生态概览

一、实训说明

1、背景知识

并行计算是高性能计算与 AI 训练的核心技术。MUSA 为摩尔线程自研统一架构，支持基于标准 C/C++ 开发 GPU 并行核函数。

本实训要求学员掌握 C 语言基础语法、Linux 常用 Shell 命令、CPU 串行、GPU 并行的基础架构等基础知识。

2、实训目的

完成本实训学习与实操后，学员将能够：

- 使用 API 查询 MUSA 硬件，读懂 MP、Warp、显存等关键参数；
- 掌握__global__与核函数启动语法，编写基础 MUSA 程序；
- 理解线程 ID 计算规则，实现数组边界防护；
- 掌握主机与设备内存分配、数据传输、资源释放全流程；
- 对比 SIMT 与 SIMD 并行模型，分析两者差异与适用场景。

3、实训时长

1课时

二、实训设计

1、关于本实训

本实训设置四个递进式实操案例，由硬件认知逐步过渡到 SIMT/SIMD 性能对比。本实训全部源码、编译脚本已提前预置在 course 只读目录，复制至 student 目录即可开展实操。

实训核心案例清单：

表 1 实训核心案例



实训资源创建中，请稍等...

预计需要 30s

温馨提示

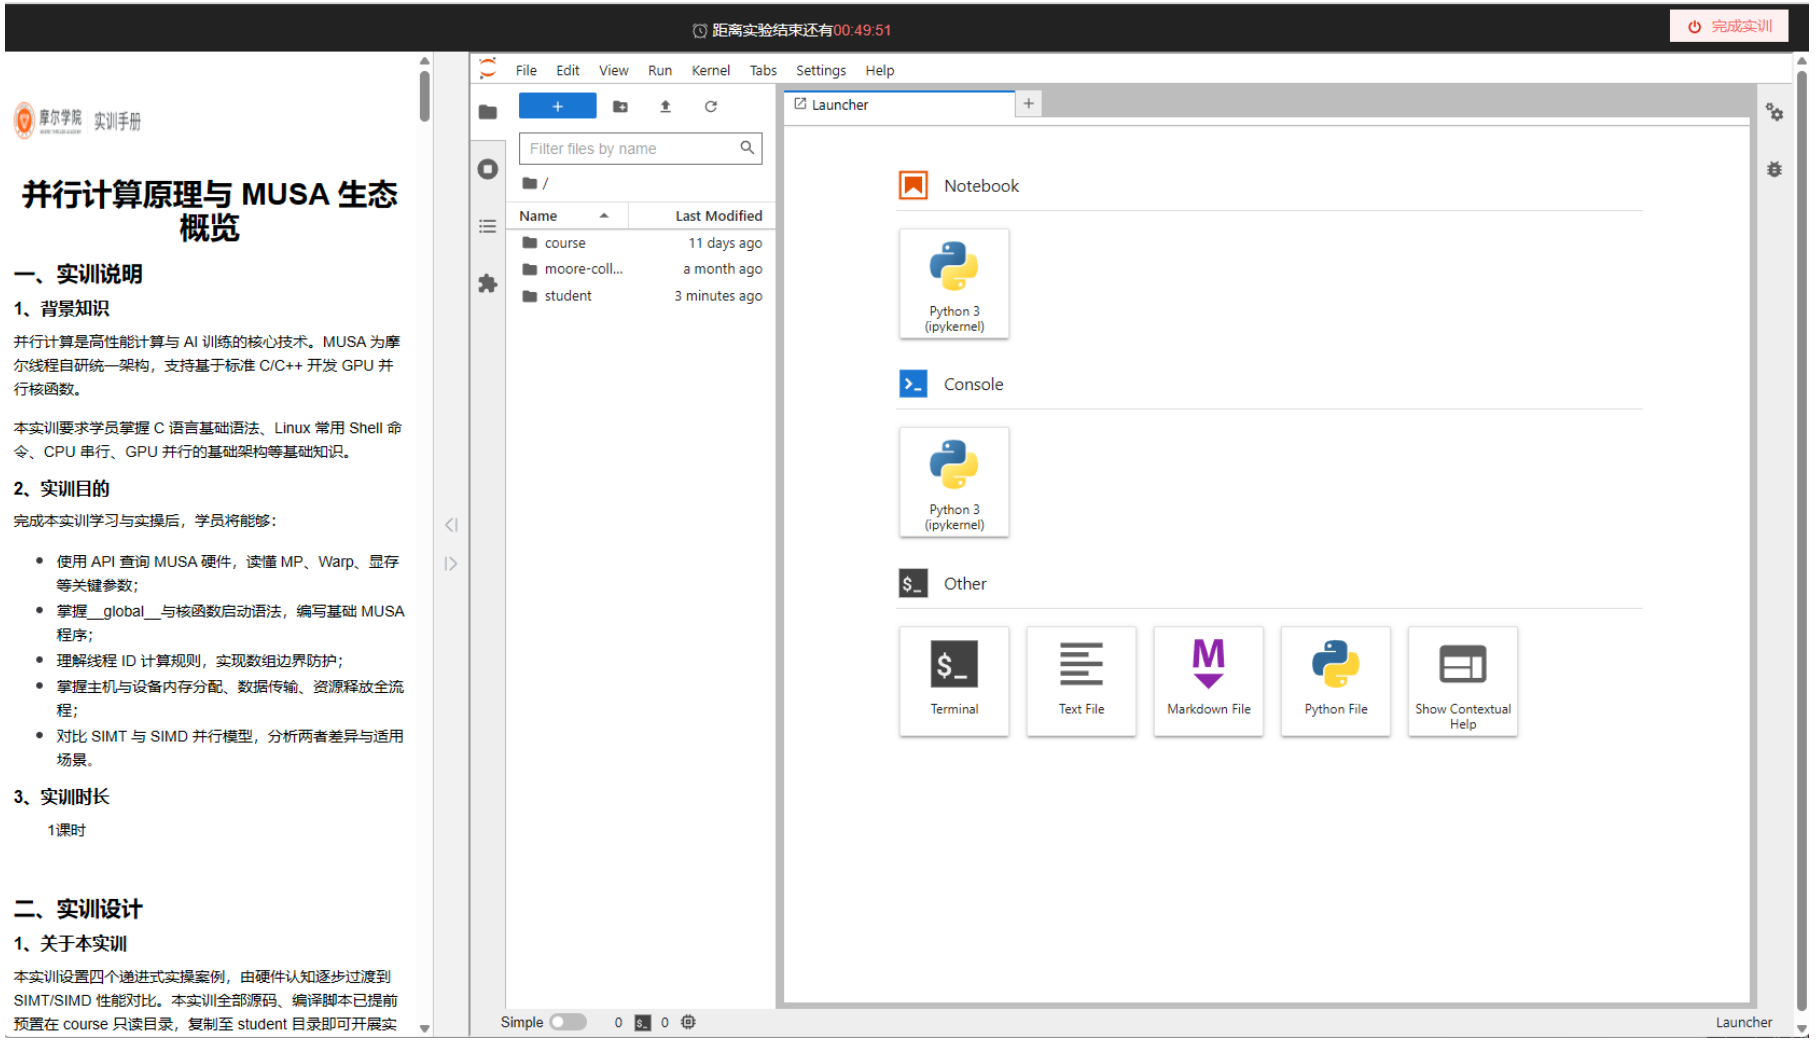
请不要关闭或刷新当前页面，刷新将导致重新排队

资源创建完成后将自动跳转

长时间未响应可联系管理员

实验阶段：以课时1为例

- 阅读学习左侧实训手册学习知识，右侧 terminal 开始实训



实验考核

- 完成课程实训内容
- 完成每堂课后面的思考题（在实训手册的最后面）



4、思考题

（1）该实训硬件 Warp 大小为 128，对比传统 GPU32 线程 Warp，对编程带来哪些影响？

（2）向量加法 blockSize 设为 100（非 128 倍数），为什么会出现性能损耗？

（3）分支场景下 SIMD 难以提速，请从架构原理分析内在原因？

（4）如何使用 MUSA 流实现 CPU、GPU 异步并行，不用同步等待？

（5）列举适合 CPU+GPU 异构协同的实际业务场景。

提交内容

- 分三次提交，完成实验内容后做思考题
- 每次提交选择其中2-3次课时的思考题
- 第一次：（MUSA基础部分）课时3,4,5思考题
- 第二次：（MUSA基础部分）课时6,7,8思考题
- 第三次：（算子部分）课时6,7,8思考题

提交方式

- 通过希冀平台提交（https://cscourse.ustc.edu.cn/admin/index.jsp）
- 账号密码均为学号
- 后续会在编译工程课程下开放作业提交入口